VI. Brief Introduction for Acoustics

[參考資料]

- 王小川，“語音訊號處理”，第三版，全華出版，台北，民國98年。
- T. F. Quatieri, *Discrete-Time Speech Signal Processing: Principle and Practice*, Pearson Education Taiwan, Taipei, 2005.
- L. R. Rabiner and R. W. Schafer, *Digital Processing of Speech Signals*, Prentice-Hall, 1978.
- P. Filippi, *Acoustics : Basic Physics, Theory, and Methods*, Academic Press, San Diego, 1999.

◉ 6-A 聲音的相關常識

人耳可以辨識頻率：20Hz ~ 20000Hz

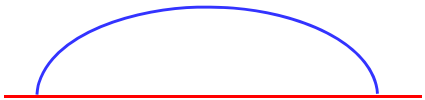

說話：150~2000Hz

電話系統頻域：小於 3500Hz

電腦音效卡取樣頻率：44100Hz (最新技術可達192K)

(一般用 22050Hz, 11025Hz 即可)

> 20000Hz: 超音波 (ultrasound)

< 20Hz: 次聲波 (infrasound)

波長較長 -> 傳播距離較遠，但容易散射

波長較短 -> 衰減較快，但傳播方向較接近直線

$e^{-\alpha dk}$, $k = \frac{2\pi}{\lambda}$

波速

- 一般聲音檔格式：
  (1) 取樣頻率 22050Hz
  (2) 單聲道或雙聲道
  (3) 每筆資料用8個bit來表示 -127~128

- 電腦中沒有經過任何壓縮的聲音檔： *.wav (without compression) mp3 (with compression)

Q: What is the data size of a song without compression?

250 × 22050 × 2 × 8 / 8 bytes

⇒ 11M

mp3 (3M~4M)

比較

image JPEG (1/30)

video MPEG (1/60)

sound mp3 (1/3)

- 數位電話取樣頻率：8000Hz

聲音在空氣中傳播速度 ： 每秒 340 公尺 (15˚C 時)

所以，人類對3000Hz 左右頻率的聲音最敏感

(一般人，耳翼到鼓膜之間的距離： 2.7公分)

$\lambda = \frac{34000}{3000} = 11.3\,cm$

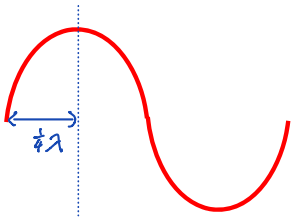

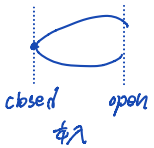

附： (1) 每增加 1˚C，聲音的速度增加 0.6 m/sec

(2) 聲音在水中的傳播速度是 1500 m/sec

在鋁棒中的傳播速度是 5000 m/sec

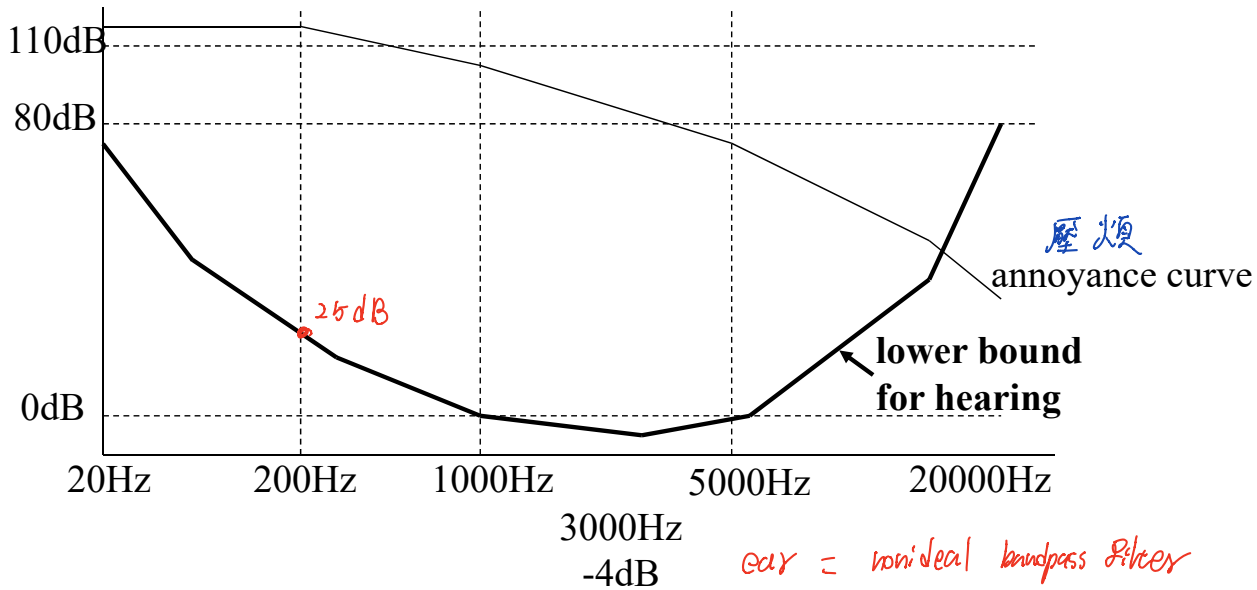
110dB
80dB
0dB
25dB
20Hz
200Hz
1000Hz
5000Hz
20000Hz
3000Hz
-4dB
annoyance curve
lower bound
for hearing

- dB: 分貝 $10\log_{10}(P/C)$，其中P為音強(正比於振福的平方)；C為0dB時的音強

每增加 10dB，音強增加10倍，振幅增加 $10^{0.5}$ 倍；
每增加3dB ，音強增加2倍，振幅增加 $2^{0.5}$ 倍；
所幸，內耳的振動不會正比於聲壓

- 人對於頻率的分辨能力，是由頻率的「比」決定

對人類而言，300Hz 和 400 Hz 之間的差別，與 3000Hz 和 4000 Hz 之間的差別是相同的

◉ 6-B Music Signal

電子琴 Do 的頻率：低音 Do: 131.32 Hz

中音 Do: 261.63 Hz

高音 Do: 523.26 Hz — 261.63 Hz

更高音 Do: 1046.52 Hz, …….

音樂每增加八度音，頻率變為 2 倍

for an instrument

for Do: 200

Re: $200 \cdot 2^{2/12}$

Mi: $200 \cdot 2^{4/12}$

每一音階有12個半音

增加一個半音，頻率增加 $2^{1/12}$ 倍 (1.0595 倍)

	Do	升Do	Re	升Re	Mi	Fa	升Fa	So	升So	La	升La	Si
Hz	262	277	294	311	330	349	370	392	415	440	466	494

$2^{1/12} \cdot 261.63$ $2^{2/12} \cdot 261.63$

音樂通常會出現「和弦」(chord) 的現象

除了基頻 f_0 Hz 之外，也會出現 $2f_0$ Hz, $3f_0$ Hz, $4f_0$ Hz , ... 的頻率

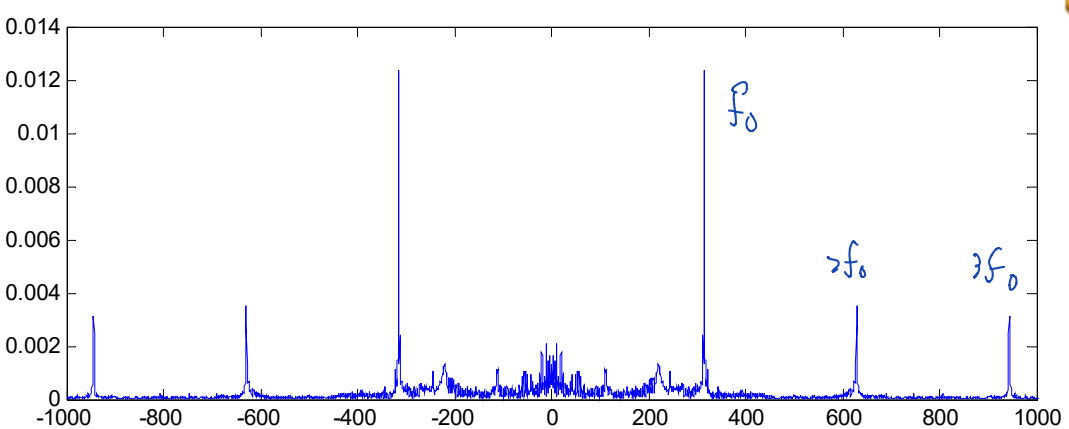

為什麼會產生和弦？ Music signal is periodic but not sinusoid

以共振的觀點：

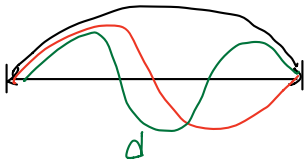

$\lambda = 2d$, $d = \frac{1}{2}\lambda$

$\lambda = d$

$d = \frac{3}{2}\lambda$

$d = \frac{k}{2}\lambda$

$(\lambda = \frac{2d}{k})$, $f = \frac{170k}{d}$

when $d = 0.515$

$f = 330k$ $\Rightarrow f = \frac{170 \cdot 10^3}{0.515}$

$x(t) = \sum_k C_k \cos(2\pi(330k)t + \phi_k)$

$x(t + \frac{1}{330}) = \sum_k C_k \cos(2\pi(330k)t + 2\pi k + \phi_k)$

$= x(t)$

$2\pi(330k)(t + \frac{1}{330}) = 2\pi 330kt + 2\pi k$

⇒ 週期性，特性不變可以消掉

聲音信號是一個 periodic signal，但是不一定是 sinusoid

◉ 6-C 語音處理的工作

(1) 語音編碼 (Speech Coding)
(2) 語音合成 (Speech Synthesis)
(3) 語音增強 (Speech Enhancement)

前三項目前基本上已經很成功

(4) 語音辨認 (Speech Recognition)

音素 → 音節 → 詞 → 句 → 整段話

目前已有很高的辨識率

(5) 說話人辨認 (Speaker Recognition)
(6) 其他：語意，語言，情緒

◎ 6-D 語音的辨認

音素 → 音節 → 詞 → 句 → 整段話

音素：相當於一個音標

(1) Spectrum Analysis

Time-Frequency Analysis

(2) Cepstrum

(3) Correlation for Words

◉ 6-E 子音和母音

ㄅ ㄆ ㄇ ㄈ ㄉ ㄊ ㄋ ㄌ ㄍ ㄎ ㄏ ㄐ ㄑ ㄒ ㄓ ㄔ ㄕ ㄖ ㄗ ㄘ ㄙ
ㄚ ㄛ ㄜ ㄝ ㄞ ㄟ ㄠ ㄡ ㄢ ㄣ ㄤ ㄦ ㄧ ㄨ ㄩ

母音： ㄚ ㄛ ㄜ ㄝ ㄞ ㄟ ㄠ ㄡ ㄢ ㄣ ㄤ ㄦ ㄧ ㄨ ㄩ

單母音： a, e, i, o, u ㄚ ㄛ ㄜ ㄝ ㄦ ㄧ ㄨ ㄩ

雙母音：ㄞ ㄟ ㄠ ㄡ

母音＋濁音：ㄢ ㄣ ㄤ ㄥ

子音： ㄅ ㄆ ㄇ ㄈ ㄉ ㄊ ㄋ ㄌ ㄍ ㄎ ㄏ ㄐ ㄑ ㄒ ㄓ ㄔ ㄕ ㄖ ㄗ ㄘ ㄙ

	ㄅ	ㄆ	ㄇ	ㄈ	ㄉ	ㄊ	ㄋ	ㄌ	ㄍ	ㄎ	ㄏ	ㄐ	ㄑ	ㄒ
漢語拚音	b	p	m	f	d	t	n	l	g	k	h	j	q	x
通用拚音	b	p	m	f	d	t	n	l	g	k	h	j	c	s

	ㄓ	ㄔ	ㄕ	ㄖ	ㄗ	ㄘ	ㄙ	ㄚ	ㄛ	ㄜ	ㄝ	ㄞ	ㄟ	ㄠ
漢語拚音	zh	ch	sh	r	z	c	s	a	o	e	e	ai	ei	ao
通用拚音	jh	ch	sh	r	z	c	s	a	o	e	e	ai	ei	ao

	ㄡ	ㄢ	ㄣ	ㄤ	ㄥ	ㄦ	ㄧ	ㄨ	ㄩ
漢語拚音	ou	an	en	ang	eng	er	i, y	u, w	yu, iu
通用拚音	ou	an	en	ang	eng	er	i, y	u, w	yu, iu

母音： 依唇型而定

子音： 在口腔，鼻腔中某些部位將氣流暫時堵住後放開

子音的能量小，頻率偏高，時間較短，出現在母音前

母音的能量大，頻率偏低，時間較長，出現在子音後或獨立出現

子音能量比較

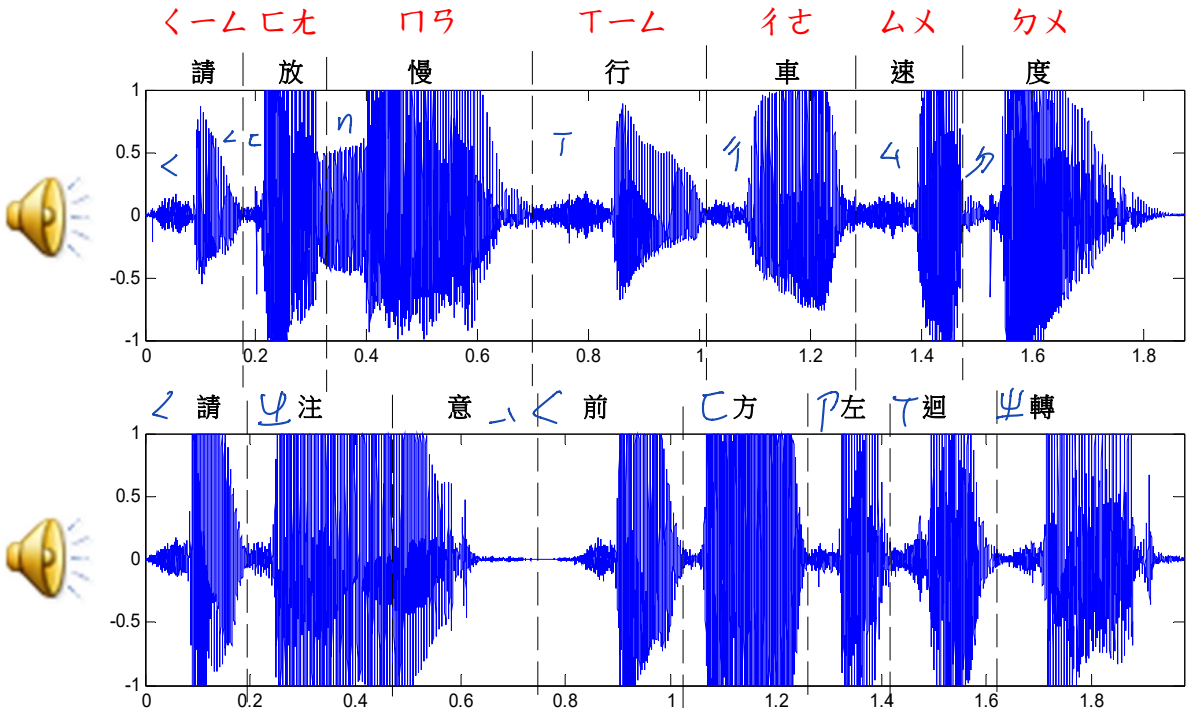
ㄑㄧㄥ ㄈㄟ ㄇㄢ ㄒㄧㄥ ㄔㄜ ㄙㄨ ㄉㄨ
請 放 慢 行 車 速 度
ㄑ ㄈ ㄇ ㄒ ㄔ ㄙ ㄉ
1
0.5
0
-0.5
-1
0 0.2 0.4 0.6 0.8 1 1.2 1.4 1.6 1.8
ㄑ請 ㄓ注 意 ㄧㄑ前 ㄈ方 ㄗ左 ㄒ迴 ㄓ轉

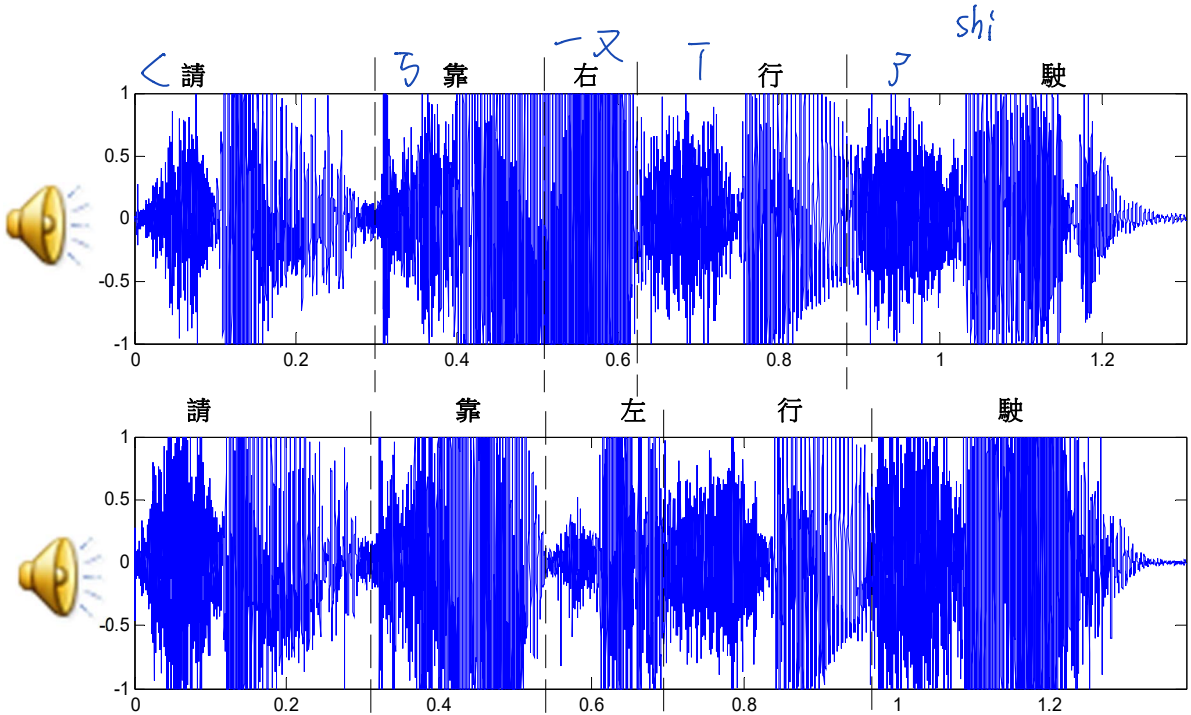
ㄑ請
ㄎ靠
ㄧㄡ
右
ㄒ
行
ㄕ
shi
駛
1
0.5
0
-0.5
-1
0
0.2
0.4
0.6
0.8
1
1.2
請
靠
左
行
駛
1
0.5
0
-0.5
-1
0
0.2
0.4
0.6
0.8
1
1.2

發音模型 (線性非時變近似)

$X(z) = R(z)H(z)G(z)E_p(z)$

$R(z)$ ：嘴唇模型， $H(z)$: 口腔模型， $G(z)$：聲帶模型
$Ep(z)$：輸入(假設為週期脈衝)

音量和 $E_p(z)$, $G(z)$ 有關
子音和 $H(z)$, $R(z)$有關
母音和 $R(z)$有關

茶

de → te → tea → tea
法 英

- 分析一個聲音信號的頻譜：

  用**Windowed Fourier Transform**

  或稱作 **Short-Time Fourier Transform**

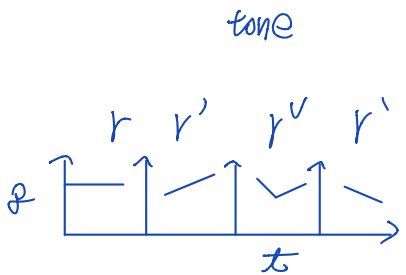

- Fourier transform

$$G(f)=\int_{-\infty}^{\infty} g(t)e^{-j2\pi ft}dt$$

Windowed Fourier transform

$$G(f)=\int_{t_0-B}^{t_0+B} g(t)e^{-j2\pi ft}dt$$

強調 $t=t_0$ 附近的區域

或 $$G(t,f)=\int_{-\infty}^{\infty} w(t-\tau)g(\tau)e^{-j2\pi f\tau}d\tau$$

典型的聲音頻譜 (不考慮倍頻)：

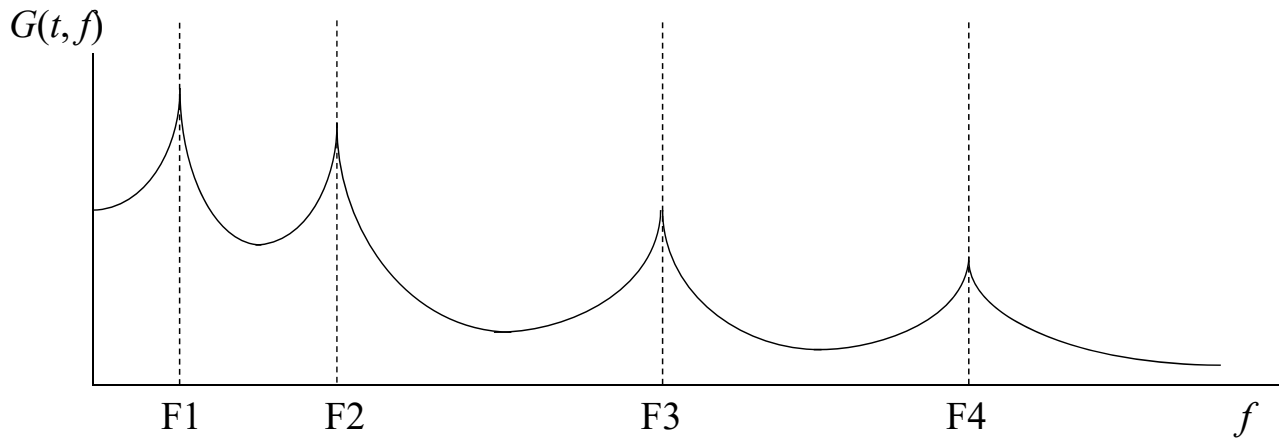

頻譜上，大部分的地方都不等於0。

出現幾個 peaks 值

可以依據 peaks 的位置來辨別母音

母音 peaks 處的頻率 (Hz) (不考慮倍頻)：

	男聲			女聲		
	F1	F2	F3	F1	F2	F3
ㄚ	900	1200	2900	1100	1350	3100
ㄛ	560	800	3000	730	1100	3200
ㄜ	560	1090	3000	790	1250	3100
ㄝ	500	2100	3100	600	2400	3300
ㄧ	310	2300	3300	360	3000	3500
ㄨ	370	540	3400	460	820	3700
ㄩ	300	2100	3400	350	2600	3200
儿	580	1500	3200	760	1700	3200

原則上： (1) 嘴唇的大小，決定F1

(2) 舌面的高低，決定 F2 – F1

- 雙母音：　ㄚㄧ　ㄝㄧ　ㄚㄛ　ㄛㄨ

  ㄞ (ai)，　ㄟ (ei)，　ㄠ (ao)，　ㄡ (ou)

  頻譜隨時間而改變，一開使始像第一個母音，後變得像另一個母音

ㄞ 的頻譜 的 peaks位置

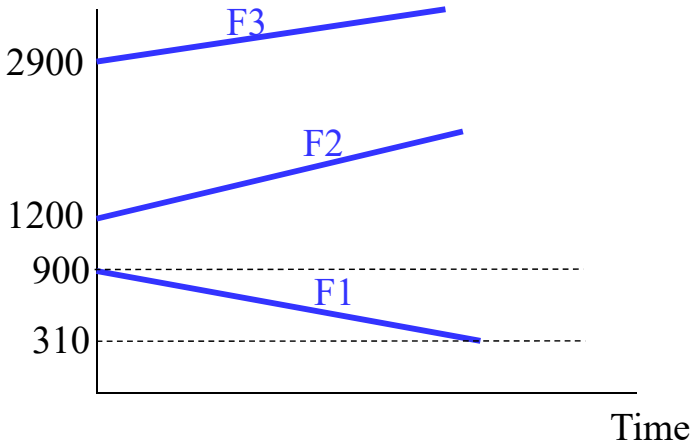

◉ 6-F 語意學的角色

relations among characters

以「語意學」或「機率」來補足語音辨識的不足

例如：經過判定，一個聲音可能是

ㄅㄧ ㄖㄢ　　ㄆㄧ ㄖㄢ

ㄅㄧ ㄌㄢ　　ㄆㄧ ㄌㄢ

這個聲音是「必然」的機率比較大。

ㄅㄛ ㄅㄛ　　ㄆㄛ ㄆㄛ

可能是「伯伯」，也可能是「婆婆」，看上下文儲存詞庫

- **當前主流的語音辨識技術：**

Mel-Frequency Cepstrum + 語意分析 + Machine Learning (人工智慧的一種)

附錄七之一：線性代數觀念補充

(1) **x** 和 **y** 兩個向量的內積可表示成 $<\mathbf{x}|\mathbf{y}>$

(2) 兩個互相正交(orthogonal)或垂直(perpendicular)的向量，其內積為0。
可表示成:$<\mathbf{x}|\mathbf{y}>=0$ 或 $<\mathbf{x},\mathbf{y}>=0$

(3) 令 S 為內積空間V的一組正交集合(set)且由非零向量構成，

$$\text{其中} \quad \mathbf{x}=\sum_{\mathbf{y}\in S} a_y \mathbf{y}, \qquad a_y=\frac{<\mathbf{x}|\mathbf{y}>}{<\mathbf{y}|\mathbf{y}>}$$

如果 S 是由一組正規集合(orthonormal set)構成，那麼 $a_y=<\mathbf{x}|\mathbf{y}>$

(4) Gram-Schmidt algorithm: 對於內積空間V的任意一組基底 $< \mathbf{x}_1, \mathbf{x}_2, ..., \mathbf{x}_n >$ ，我們可以透過這演算法找到一組正交基底 $< \mathbf{y}_1, \mathbf{y}_2, ..., \mathbf{y}_n >$

$$\mathbf{y}_j = \mathbf{x}_j - \sum_{i=1}^{j-1} \frac{< \mathbf{x}_j \mid \mathbf{y}_i >}{< \mathbf{y}_i \mid \mathbf{y}_i >} \mathbf{y}_i \quad for \ \ each \ j = 2, ..., n$$

幾何意義:把 $\mathbf{x}_j$ 在 $\mathbf{y}_1, \mathbf{y}_2, \ldots, \mathbf{y}_{j-1}$ 上面的分向量全都從向量 $\mathbf{x}_j$ 身上扣掉之後，剩下的向量 $\mathbf{y}_j$ 自然就會跟 $\mathbf{y}_1, \mathbf{y}_2, \ldots, \mathbf{y}_{j-1}$ 垂直。

(5) Solving $\mathbf{Ax} = \mathbf{b}$ but $size(\mathbf{A}) = m \times n$ *and* $\mathbf{b} \in F^m$, $m > n$

Interpolation Theorem (插值定理)

1. For any inner-product function of F^m , there exists a vector $\mathbf{z}$ that minimizes $\| \mathbf{Az} - \mathbf{b} \|$ where $\mathbf{z} \in F^n$

2. If rank($\mathbf{A}$) = n, then $\mathbf{z} = \left(\mathbf{A}^H \mathbf{A} \right)^{-1} \mathbf{A}^H \mathbf{b}$ is the unique minimizer of $\| \mathbf{Az} - \mathbf{b} \|$

附錄七之二：PCA and SVD

PCA (principal component analysis) 是資料分析和影像處理當中常用到的數學方法，用來分析資料的「主要成分」或是影像中物體的「主軸」。

它其實和各位同學在高中和大一線代所學的回歸線 (regressive line) 很類似。回歸線是用一條一維 (one-dimensional) 的直線來近似二維 (two-dimensional) 的資料，而 PCA 則是用 *M*-dimensional data 來近似 *N*-dimensional data ，其中 *M* 小於等於 *N*

在講解 PCA 之前，先介紹什麼是 SVD (singular value decomposition)

我們在大一的時候，都已經學到該如何對於 *N* x *N* 的矩陣做 eigenvector-eigenvalue decomposition
那麼……
當一個矩陣的 size 為 *M* x *N*，且 *M* 和 *N* 不相等時，我們該如何對它來做 eigenvector-eigenvalue decomposition?

SVD 的流程：

假設 **A** 是一個 M x N 的矩陣。

(Step 1) 計算

$$\mathbf{B} = \mathbf{A}^{\mathbf{H}}\mathbf{A} \qquad \mathbf{C} = \mathbf{A}\mathbf{A}^{\mathbf{H}}$$

2×2 5×5

注意，**B** 是 N x N 的矩陣，而 **C** 是 M x M 的矩陣。上標H代表 Hermitian matrix，相當於做共軛轉置。

(Step 2) 接著，對 **B** 和 **C** 做 eigenvector-eigenvalue decomposition

$$\mathbf{B} = \mathbf{V}\mathbf{D}\mathbf{V}^{-1} \qquad \mathbf{C} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^{-1}$$

其中 **V** 的每一個 column 是 **B** 的 eigenvector (with normalization)，**U** 的每一個 column 是 **C** 的 eigenvector (with normalization)，**Λ** 和 **D** 都是對角矩陣，**Λ** 和 **D** 對角線上的 entries 是 **B** 和 **C** 的 eigenvalues。並假設 eigenvectors 根據 eigenvalues 的大小排序 (由大到小)

Note: 值得注意的是，由於 $\mathbf{B} = \mathbf{B}^{\mathbf{H}}$ 且 $\mathbf{C} = \mathbf{C}^{\mathbf{H}}$，所以 **B** 和 **C** 的 eigenvectors 皆各自形成一個 orthogonal set。經過適當的 normalization 使得 **U** 和 **V** 的 column 自己和自己的內積為 1 之後，$\mathbf{U}^{-1} = \mathbf{U}^{\mathbf{H}}$ 和 $\mathbf{V}^{-1} = \mathbf{V}^{\mathbf{H}}$將滿足。因此，**B** 和 **C** 可以表示成

$$\mathbf{B} = \mathbf{V}\mathbf{D}\mathbf{V}^{\mathbf{H}} \qquad \mathbf{C} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^{\mathbf{H}}$$

注意，**V**和**U**是unitary matrix

(Step 3) 計算

$$\mathbf{S}_1 = \mathbf{U}^{\mathbf{H}}\mathbf{A}\mathbf{V} \qquad A = USV^H$$

$\mathbf{S}_1$ 是一個 M x N 的矩陣，只有在 $\mathbf{S}_1[n, n]$ $(n = 1, 2, \ldots, \min(M, N))$ 的地方不為 0

(Step 4) $\mathbf{S} = |\mathbf{S}_1|$ 取絕對值

若 $\boldsymbol{S}_1[n, n] < 0$，改變 **U** 第 n 個 column 的正負號

即完成 SVD

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^{\mathbf{H}}$$

Note: Since **V** is bound to be real,

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^{\mathbf{T}}$$

A 也可以表示為

$$\mathbf{A} = \lambda_1\mathbf{u}_1\mathbf{v}_1^{\mathbf{T}} + \lambda_2\mathbf{u}_2\mathbf{v}_2^{\mathbf{T}} + \cdots\cdots + \lambda_k\mathbf{u}_k\mathbf{v}_k^{\mathbf{T}}$$

其中 $\lambda_n = \boldsymbol{S}[n, n]$, $k = \min(M, N))$

註： Matlab 有內建的 svd 指令可以計算 SVD

從 SVD 到 PCA (principal component analysis ，主成份分析)

$$\mathbf{A} = \lambda_1 \mathbf{u_1} \mathbf{v_1^T} + \lambda_2 \mathbf{u_2} \mathbf{v_2^T} + \cdots\cdots + \lambda_k \mathbf{u_k} \mathbf{v_k^T} \qquad k = \min(M, N))$$

若 $\lambda_1 \geqq \lambda_2 \geqq \lambda_3 \geqq \ldots\ldots \geqq \lambda_k$

$\lambda_1 \mathbf{u_1} \mathbf{v_1^T}$ 是 A 矩陣的最主要的成份

$\lambda_2 \mathbf{u_2} \mathbf{v_2^T}$ 是 A 矩陣的第二主要的成份

:

:

$\lambda_k \mathbf{u_k} \mathbf{v_k^T}$ 是 A 矩陣的最不重要的成份

若為了壓縮或是去除雜訊的考量，可以選擇 $h < k$，使得 **A** 可以近似成

$$\mathbf{A} \cong \lambda_1 \mathbf{u_1} \mathbf{v_1^T} + \lambda_2 \mathbf{u_2} \mathbf{v_2^T} + \cdots\cdots + \lambda_h \mathbf{u_h} \mathbf{v_h^T}$$

PCA 的流程

假設現在有 M 筆資料，每一筆資料 為 N dimension

$$\mathbf{g_1} = [f_{1,1}\ f_{1,2}, \ldots, f_{1,N}]$$
$$\mathbf{g_2} = [f_{2,1}\ f_{2,2}, \ldots, f_{2,N}]$$
$$\vdots$$
$$\mathbf{g_M} = [f_{M,1}\ f_{M,2}, \ldots, f_{M,N}]$$

(Step 1) 扣掉平均值，形成新的 data

$$\mathbf{d_m} = \left[e_{m,1}\ \ e_{m,2}\ \ \cdots\cdots e_{m,N} \right] \qquad m = 1, 2, \ldots, M$$

其中 $e_{m,n} = f_{m,n} - \tilde{f}_n, \qquad \tilde{f}_n = \dfrac{1}{M}\sum_{m=1}^{M} f_{m,n}$

(Step 2) 形成 M x N 的矩陣 **A**

A 的第 m 個 row 為 d_m , $\qquad m = 1, 2, \ldots, M$

(Step 3) 對 A 做 SVD 分解

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^{\mathbf{H}}$$

$$= \lambda_1 \mathbf{u_1} \mathbf{v_1^T} + \lambda_2 \mathbf{u_2} \mathbf{v_2^T} + \cdots\cdots + \lambda_k \mathbf{u_k} \mathbf{v_k^T} \qquad k = \min(M, N))$$

$$\lambda_1 \geqq \lambda_2 \geqq \lambda_3 \geqq \ldots\ldots \geqq \lambda_k$$

(Step 4) 將 A 近似成

$$\mathbf{A} \cong \lambda_1 \mathbf{u_1} \mathbf{v_1^T} + \lambda_2 \mathbf{u_2} \mathbf{v_2^T} + \cdots\cdots + \lambda_h \mathbf{u_h} \mathbf{v_h^T}$$

則每一筆資料可以近似為

$$g_{\mathbf{m}} \cong \lambda_1 u_1[m] \mathbf{v_1^T} + \lambda_2 u_2[m] \mathbf{v_2^T} + \cdots\cdots + \lambda_h u_h[m] \mathbf{v_h^T} + \begin{bmatrix} \tilde{f}_1 & \tilde{f}_2 & \cdots & \tilde{f}_N \end{bmatrix}$$

除了平均值 $\begin{bmatrix} \tilde{f}_1 & \tilde{f}_2 & \cdots & \tilde{f}_N \end{bmatrix}$ 之外

$\mathbf{v_1^T}$ 是資料的最主要成分，$\mathbf{v_2^T}$ 是資料的次主要成分，
$\mathbf{v_3^T}$ 是資料的第三主要成分，以此類推

Example of PCA

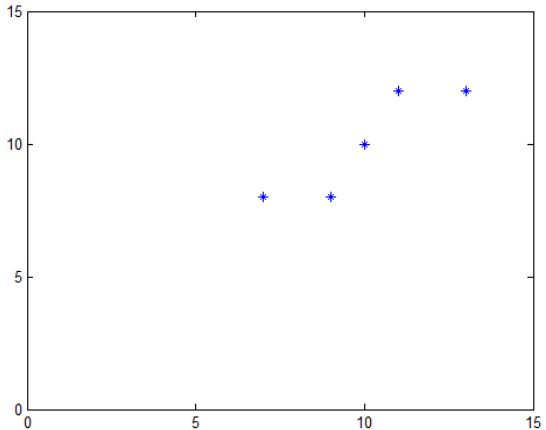

假設在一個二維的空間中，有5個點，座標分別是

(7,8), (9,8), (10, 10), (11,12), (13,12)

$M = 5, N = 2$

試求這五個點的 PCA (即回歸線)

(Step 1) 將這五個座標點減去平均值 (10, 10)

(-3, -2), (-1 -2), (0, 0), (1, 2), (3, 2)

(Step 2) 形成 5x2 的 matrix

$$\mathbf{A} = \begin{bmatrix} -3 & -2 \\ -1 & -2 \\ 0 & 0 \\ 1 & 2 \\ 3 & 2 \end{bmatrix}$$

(Step 3) 計算 SVD = find eigenvector / eigenvalues for a non-square matrix

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^{\mathbf{H}}$$

$$\mathbf{U} = \begin{bmatrix} -0.6116 & 0.3549 & 0 & 0.0393 & 0.7060 \\ -0.3549 & -0.6116 & 0 & 0.7060 & -0.0393 \\ 0 & 0 & 1 & 0 & 0 \\ 0.3549 & 0.6116 & 0 & 0.7060 & -0.0393 \\ 0.6116 & -0.3549 & 0 & 0.0393 & 0.7060 \end{bmatrix} \quad \mathbf{S} = \begin{bmatrix} 5.8416 & 0 \\ 0 & 1.3695 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

5x2

$$\mathbf{V} = \begin{bmatrix} 0.7497 & -0.6618 \\ 0.6618 & 0.7497 \end{bmatrix}$$

主成分 次要成分

$$\mathbf{A} = 5.8416 \begin{bmatrix} -0.6116 \\ -0.3549 \\ 0 \\ 0.3549 \\ 0.6116 \end{bmatrix} \begin{bmatrix} 0.7497 & 0.6618 \end{bmatrix} + 1.3695 \begin{bmatrix} 0.3549 \\ -0.6116 \\ 0 \\ 0.6116 \\ -0.3549 \end{bmatrix} \begin{bmatrix} -0.6618 & 0.7497 \end{bmatrix}$$

(Step 4) 得到主成分 $[0.7497 \quad 0.6618]$

這五個座標點可以近似成

$$5.8416 \cdot u_m [0.7497 \quad 0.6618] + [10 \quad 10] \qquad m = 1, 2, \ldots, 5$$

$$u_1 = -0.6116, \quad u_2 = -0.3549, \quad u_3 = 0, \quad u_4 = 0.3549, \quad u_5 = 0.6116$$

回歸線

$$[10 \quad 10] + c[0.7497 \quad 0.6618]$$

$$c \in (-\infty, \infty)$$